

DOCUMENTACIÓN DEL PROYECTO DE BUSINESS ANALYTICS

Reto 9 — Predicción de Churn con Inteligencia Artificial

El Mercado de las Especias de Dataclysm

Autora: Judit Giravent

Fecha: 09/2026

Herramientas: Python 3.13 · scikit-learn · TensorFlow/Keras · Power BI

Dataset: Telco Customer Churn (Kaggle — IBM)

Índice

1. Resumen ejecutivo
 2. Definición del problema y objetivos
 3. Selección y recolección de datos
 4. Análisis Exploratorio de Datos (EDA)
 5. Preparación y limpieza de datos
 6. Desarrollo de modelos avanzados de IA
 7. Evaluación de modelos
 8. Interpretación de resultados
 9. Recomendaciones estratégicas
 10. Conclusiones
 11. Anexos
-

1. Resumen ejecutivo

Este proyecto desarrolla un **sistema de predicción de churn** (abandono de clientes) para una empresa de telecomunicaciones, aplicando **4 modelos avanzados de Inteligencia Artificial** sobre un dataset de 7.043 clientes.

Objetivos principales

- **Predecir** qué clientes tienen alta probabilidad de abandonar el servicio.
- **Identificar** los factores más influyentes en el churn.
- **Recomendar** acciones concretas para reducir la tasa de abandono.

Técnicas aplicadas

#	Modelo	Tipo	AUC-ROC	F1
1	Regresión Logística	Baseline	0.8418	0.6157
2	Random Forest	Ensemble (ganador)	0.8445 ☆	0.6350 ☆
3	Gradient Boosting	Ensemble	0.8435	0.6213
4	Red Neuronal	Deep Learning	0.8310	0.6187

Hallazgos principales

1. **El 26,54% de los clientes abandonan** (1.869 de 7.043).
2. **El tipo de contrato es el factor más determinante:**
 - Month-to-month: **42,7% churn**
 - One year: 11,3% churn
 - Two year: **2,8% churn**
3. **Los clientes nuevos abandonan más:** tenure medio de 18 meses (churners) vs 37,6 (no churners).
4. **El servicio de Fibra Óptica tiene más churn** (41,9%) que DSL (19%) o sin internet (7,4%).
5. **El Random Forest es el mejor modelo** con AUC-ROC 0.8445 y F1 0.6350.

Conclusión

El modelo **Random Forest** permite identificar al **78,6% de los clientes que abandonarán**, ofreciendo una herramienta accionable para **reducir el churn hasta un 20%** mediante campañas segmentadas.

2. Definición del problema y objetivos

2.1 Contexto empresarial

El sector de las **telecomunicaciones** se caracteriza por:

- Alta competencia y saturación del mercado.
- Coste elevado de captación de nuevos clientes (~5-7x más que retener).
- Tasa de churn media del 15-25% anual.

El churn es uno de los problemas más costosos para las empresas de telecomunicaciones.

2.2 Problema central

¿Qué clientes tienen alta probabilidad de abandonar el servicio, y por qué?

Identificar proactivamente a los clientes en riesgo permite **actuar antes de perderlos**.

2.3 Objetivos específicos

#	Objetivo	Métrica
1	Construir un modelo predictivo de churn	AUC-ROC > 0.80
2	Identificar las variables más influyentes	Feature importance
3	Segmentar a los clientes por riesgo	Probabilidad de churn
4	Proponer acciones de retención	Recomendaciones

2.4 Preguntas clave del análisis

- ¿Qué características de los clientes están asociadas con el churn?
- ¿Qué modelo predice mejor el abandono?
- ¿Qué acciones concretas pueden reducir la tasa de churn?
- ¿Cuál es el impacto económico esperado de las recomendaciones?

2.5 Enfoque analítico

Tipo de análisis	Uso
Descriptivo	Entender el dataset y patrones históricos
Predictivo	Predecir el churn con ML/Deep Learning
Prescriptivo	Recomendar acciones de retención

2.6 Métricas clave

Métrica	Objetivo	Justificación
AUC-ROC	> 0.80	Métrica principal para clasificación binaria
F1-score	> 0.60	Balance Precision/Recall
Recall	Priorizar	Detectar el máximo de churners

3. Selección y recolección de datos

3.1 Fuente de datos

Característica	Valor
Nombre	Telco Customer Churn (IBM Sample Data)
Fuente	Kaggle

Característica	Valor
URL	https://www.kaggle.com/datasets/blastchar/telco-customer-churn
Registros	7.043 clientes
Variables	21 columnas
Formato	CSV

3.2 Justificación

- **Dataset real** de IBM, ampliamente usado en la industria.
- **Problema de negocio claro**: predecir churn.
- **Compatible con todos los modelos** requeridos (ML clásico + Deep Learning).
- **Tamaño adecuado** para entrenar modelos sin necesidad de infraestructura pesada.
- **Métricas estándar** (AUC-ROC, F1, etc.) directamente aplicables.

3.3 Variables del dataset

Variable	Tipo	Descripción
customerID	Texto	ID único del cliente
gender	Categórica	Male / Female
SeniorCitizen	Binaria	0/1 (¿es mayor de 65 años?)
Partner	Categórica	Yes / No
Dependents	Categórica	Yes / No
tenure	Numérica	Meses como cliente
PhoneService	Categórica	Yes / No
MultipleLines	Categórica	Yes / No / No phone service
InternetService	Categórica	DSL / Fiber optic / No
OnlineSecurity	Categórica	Yes / No / No internet service
OnlineBackup	Categórica	Yes / No / No internet service
DeviceProtection	Categórica	Yes / No / No internet service
TechSupport	Categórica	Yes / No / No internet service
StreamingTV	Categórica	Yes / No / No internet service
StreamingMovies	Categórica	Yes / No / No internet service
Contract	Categórica	Month-to-month / One year / Two year

Variable	Tipo	Descripción
PaperlessBilling	Categórica	Yes / No
PaymentMethod	Categórica	4 métodos de pago
MonthlyCharges	Numérica	Cargo mensual (€)
TotalCharges	Numérica	Cargo total acumulado (€)
Churn	Objetivo	Yes / No

3.4 Validación inicial

- Sin valores nulos en ninguna columna.
- Sin filas duplicadas.
- 11 valores vacíos en TotalCharges (tratados en la preparación).

4. Análisis Exploratorio de Datos (EDA)

4.1 Distribución de la variable objetivo

Churn	Clientes	%
No	5.174	73,46%
Yes	1.869	26,54%

Observación: el dataset está **moderadamente desbalanceado** (73/27). Requiere tratamiento con `class_weight='balanced'` en los modelos.

4.2 Estadísticas descriptivas

Variable	Media	Mediana	Desv. Est.	Máximo
tenure (meses)	32,37	29,00	24,56	72
MonthlyCharges (€)	64,76	70,35	30,09	118,75

4.3 Distribución de variables categóricas clave

Por tipo de contrato

Contract	No Churn	Churn	% Churn
Month-to-month	2.220	1.655	42,7%
One year	1.307	166	11,3%

Contract	No Churn	Churn	% Churn
Two year	1.647	48	2,8%

Hallazgo: los contratos mensuales tienen **15x más churn** que los de 2 años.

Por servicio de internet

InternetService	No Churn	Churn	% Churn
DSL	1.961	459	19,0%
Fiber optic	1.799	1.297	41,9%
No	1.414	113	7,4%

Hallazgo: la **Fibra Óptica tiene el mayor churn** (probablemente por precio elevado o expectativas no cumplidas).

Por antigüedad y facturación

Variable	No Churn	Churn
tenure medio	37,57 meses	17,98 meses
MonthlyCharges medio	61,27 €	74,44 €

Hallazgo: los churners son clientes **más nuevos** y con **mayor facturación mensual**.

4.4 Visualizaciones clave

Figura	Descripción
01_distribucion_churn.png	Distribución de la variable objetivo
02_variables_numericas_churn.png	Boxplots de tenure, MonthlyCharges y TotalCharges por Churn
03_categoricas_vs_churn.png	Churn por tipo de contrato, servicio, etc.
04_correlaciones.png	Matriz de correlación de variables numéricas

4.5 Hallazgos del EDA

- 1. **El churn afecta al 26,54%** de los clientes.
 - 2. **Tipo de contrato** es el factor más discriminante.
 - 3. **Los clientes nuevos** (bajo tenure) son los más propensos a abandonar.
 - 4. **Fibra óptica** concentra el mayor churn (41,9%).
 - 5. **Los churners pagan más** (74,44€ vs 61,27€).
-

5. Preparación y limpieza de datos

5.1 Tratamiento de valores faltantes

Problema: `TotalCharges` venía como texto con **11 valores vacíos**.

Solución aplicada:

1. Conversión a numérico con `pd.to_numeric(errors='coerce')`.
2. Imputación de los 11 vacíos con `MonthlyCharges` (clientes nuevos).

5.2 Eliminación de variables irrelevantes

- `customerID`: eliminado (identificador único sin valor predictivo).

5.3 Codificación de variables categóricas

Variables binarias (Yes/No → 1/0)

Variable	Tipo
<code>Partner</code>	Binaria
<code>Dependents</code>	Binaria
<code>PhoneService</code>	Binaria
<code>PaperlessBilling</code>	Binaria
<code>gender</code>	Male=1, Female=0

Variables de servicio (Yes/No/No service → 1/0)

Se simplificaron las categorías "No internet service" y "No phone service" a "No":

- `MultipleLines`
- `OnlineSecurity`
- `OnlineBackup`
- `DeviceProtection`
- `TechSupport`
- `StreamingTV`
- `StreamingMovies`

Variables multicategoría (One-Hot Encoding)

- **InternetService:** 3 columnas (`DSL`, `Fiber optic`, `No`)
- **Contract:** 3 columnas (`Month-to-month`, `One year`, `Two year`)
- **PaymentMethod:** 4 columnas

Resultado: 27 columnas en total (26 features + 1 target).

5.4 División train/test

Conjunto	Registros	% Churn
Train	5.634 (80%)	26,54%
Test	1.409 (20%)	26,54%

Método: división estratificada para mantener el desbalance.

5.5 Normalización


Se aplicó **StandardScaler** (media=0, std=1) a las 3 variables numéricas continuas:

- ♦ `tenure`
- ♦ `MonthlyCharges`
- ♦ `TotalCharges`

Importante: el scaler se ajustó **solo en train** para evitar data leakage, y se aplicó a test con `transform()`.

5.6 Visualización

- `05_train_test_split.png` : Distribución de Churn en train y test.



6. Desarrollo de modelos avanzados de IA

6.1 Estrategia de modelado

Se entrenaron **4 modelos** con complejidad creciente:

#	Modelo	Tipo	Justificación
1	Regresión Logística	Baseline	Interpretabilidad, punto de referencia
2	Random Forest	Ensemble (bagging)	Robusto, captura no linealidad
3	Gradient Boosting	Ensemble (boosting)	Precisión, mejor en datos tabulares
4	Red Neuronal	Deep Learning	Captura relaciones muy no lineales

6.2 Tratamiento `class_weight='balanced'` Todos los modelos usan

(o `sample_weight` equivalente) para compensar el desbalance 73/27. Esto prioriza detectar churners aunque baje ligeramente la Precision.

6.3 Modelo 1: Regresión Logística

Configuración:


- ♦ `max_iter=1000`
- ♦ `class_weight='balanced'`

♦ random_state=42


Top 5 coeficientes más influyentes:

Variable	Coeficiente	Efecto
InternetService_No	-1.23	Reduce churn
tenure	-1.15	Reduce churn
Contract_Two year	-0.88	Reduce churn
InternetService_Fiber optic	+0.88	Aumenta churn
Contract_Month-to-month	+0.55	Aumenta churn


Figuras: 06_confusion_logistica.png , 07_roc_logistica.png , 08_coeficientes_logistica.png .



Curva ROC — Regresión Logística



Top 15 variables más influyentes (Regresión Logística)



6.4 Modelo 2: Random Forest


Configuración:

- ♦ `n_estimators=200`
- ♦ `max_depth=10`
- ♦ `min_samples_split=10`, `min_samples_leaf=5`
- ♦ `class_weight='balanced'`


Top 5 variables más importantes:

Variable	Importancia
Contract_Month-to-month	0.172
tenure	0.147
TotalCharges	0.112
MonthlyCharges	0.109
Contract_Two year	0.080


Figuras: `09_confusion_random_forest.png`, `10_roc_random_forest.png`, `11_importancia_random_forest.png`.



Curva ROC — Random Forest



Top 15 variables más importantes (Random Forest)



6.5 Modelo 3: Gradient Boosting

Configuración:

- ♦ `n_estimators=200`
- ♦ `learning_rate=0.05`
- ♦ `max_depth=4`
- ♦ `subsample=0.8`


- ♦ `sample_weight` con peso 3x para churners



Top 5 variables:

Variable	Importancia
Contract_Month-to-month	0.414 ☆
TotalCharges	0.117
MonthlyCharges	0.109
tenure	0.107
InternetService_Fiber optic	0.068

Observación: el modelo se apoya casi exclusivamente en el **tipo de contrato** (41,4% de la importancia).

Figuras: `12_confusion_gradient_boosting.png`, `13_roc_gradient_boosting.png`, `14_importancia_gradient_boosting.png`.





6.6 Modelo 4: Red Neuronal (Deep Learning)

Entorno: Google Colab con TensorFlow 2.20.

Arquitectura:

```
Input (26 features)
↓
Dense(64, relu) + BatchNormalization + Dropout(0.3)
```

```
↓  
Dense(32, relu) + BatchNormalization + Dropout(0.3)  
↓  
Dense(16, relu) + Dropout(0.2)  
↓
```

Total parámetros: 4.737

Configuración:


- Optimizer: `Adam(learning_rate=0.001)`
- Loss: `binary_crossentropy`
- Métricas: `accuracy`, `AUC`
- **EarlyStopping** (patience=15)
- **ReduceLROnPlateau** (factor=0.5)
- **class_weight** calculado automáticamente


Observación importante: el EarlyStopping se activó en la **época 17** y restauró los pesos de la **época 2**. Esto sugiere que el modelo no mejoró más allá del inicio del entrenamiento, probablemente porque:

- El dataset tiene **pocas features (26)** para una red neuronal.

- **5.600 muestras** son pocas para Deep Learning.
- Los modelos de **ensemble (RF, GB)** son más adecuados para datos tabulares.

Figuras: 15_curvas_entrenamiento.png , 16_confusion_red_neuronal.png , 17_roc_red_neuronal.png .





6.7 Modelos guardados

Archivo	Formato
<code>modelo_regresion_logistica.pkl</code>	pickle
<code>modelo_random_forest.pkl</code>	pickle
<code>modelo_gradient_boosting.pkl</code>	pickle
<code>modelo_red_neuronal.keras</code>	Keras
<code>scaler.pkl</code>	pickle (StandardScaler)

7. Evaluación de modelos

7.1 Tabla comparativa final

Modelo	Accuracy	Precision	Recall	F1	AUC-ROC
Random Forest	0.7601 ☆	0.5326 ☆	0.7861 ☆	0.6350 ☆	0.8445 ☆
Gradient Boosting	0.7473	0.5159	0.7807	0.6213	0.8435
Regresión Logística	0.7395	0.5060	0.7861	0.6157	0.8418
Red Neuronal	0.7516	0.5221	0.7594	0.6187	0.8310

7.2 Análisis por métrica

- **Accuracy:** Random Forest gana (0.7601).

- **Precision:** Random Forest gana (0.5326) → menos falsos positivos.
- **Recall:** Empate entre RF y Logística (0.7861) → detectan 294 churners de 374.
- **F1-score:** Random Forest gana (0.6350).
- **AUC-ROC:** Random Forest gana (0.8445) → mejor capacidad discriminativa.

7.3 Modelo seleccionado: Random Forest

Razones de la elección:


1. **Mejor en las 5 métricas.**
2. **Interpretable** mediante feature importance.
3. **Robusto** frente a outliers.

4. **Rápido de entrenar** (~5 segundos).

5. **No requiere GPU.**

7.4 Curvas ROC comparativas

Figura: 18_comparativa_4_modelos.png y 19_heatmap_modelos.png .



7.5 Ajuste de hiperparámetros

Modelo	Hiperparámetros probados	Decisión
Random Forest	max_depth : 5, 10, 15	10

Random Forest	<code>n_estimators</code> : 100, 200, 300	200
Gradient Boosting	<code>learning_rate</code> : 0.01, 0.05, 0.1	0.05
Red Neuronal	Dropout: 0.2, 0.3, 0.4	0.3, 0.3, 0.2

8. Interpretación de resultados

8.1 Factores clave del churn

Factor 1: Tipo de contrato

Contract	Tasa de churn
Month-to-month	42,7%
One year	11,3%
Two year	2,8%

Interpretación: los contratos mensuales permiten al cliente abandonar en cualquier momento sin penalización. Los contratos largos **reducen drásticamente el churn** (15x menos).

Factor 2: Antigüedad

Segmento	tenure medio
No Churn	37,57 meses
Churn	17,98 meses

Interpretación: el **riesgo se concentra en los primeros 18 meses**. Superado ese umbral, el cliente tiende a quedarse.

Factor 3: Servicio de internet

InternetService	Churn
Fiber optic	41,9%
DSL	19,0%
No	7,4%

Interpretación: la **Fibra Óptica tiene 2x más churn** que DSL, probablemente por:

- Mayor precio mensual.
- Expectativas más altas.
- Competencia más agresiva en ese segmento.

Factor 4: Cargo mensual

Segmento	MonthlyCharges
No Churn	61,27 €
Churn	74,44 €

Interpretación: los churners pagan **+21% más al mes**, lo que refuerza la hipótesis de **sensibilidad al precio**.

8.2 Segmentación por riesgo de churn

Segmentación propuesta basada en probabilidad del modelo:

Segmento	Probabilidad	Clientes	Acción
Crítico	> 0.70	~500	Contacto urgente
Alto	0.50 - 0.70	~700	Campaña de retención
Medio	0.30 - 0.50	~1.500	Seguimiento
Bajo	< 0.30	~4.300	Marketing general

9. Recomendaciones estratégicas

9.1 Recomendación 1: Incentivar contratos largos (Prioridad ALTA)

Hallazgo: los contratos Month-to-month tienen 42,7% churn vs 2,8% de Two year.

Acción:

- Ofrecer descuentos del **15-20%** por cambiar a contrato anual.
- Añadir **beneficios exclusivos** (streaming gratis, upgrade de velocidad).
- **Targeting:** clientes con >6 meses de tenure y contrato mensual.

Impacto esperado:

- Reducir churn mensual en **~10 puntos porcentuales**.
- **Retener ~150 clientes/año** con valor medio de ~900€/año.

Impacto económico estimado: ~135.000 €/año.

9.2 Recomendación 2: Programa de retención temprana (Prioridad ALTA)

Hallazgo: los churners tienen tenure medio de 18 meses.

Acción:

- **Contacto proactivo** en los primeros 6 meses.
- Onboarding mejorado con tutoriales personalizados.
- **Seguimiento del CSAT** en el mes 3, 6 y 12.
- Ofertas especiales en el **mes 12** (renovación anual).

Impacto esperado:

- Reducir churn en clientes nuevos en un **20%**.
- **Retener ~100 clientes/año** adicionales.

Impacto económico estimado: ~90.000 €/año.

9.3 Recomendación 3: Revisar la oferta de Fibra Óptica (Prioridad MEDIA-ALTA)

Hallazgo: Fibra Óptica tiene 41,9% churn.

Acción:

- **Auditar la calidad** del servicio (velocidad, caídas, atención).
- **Comparar precios** con la competencia.
- **Rediseñar el plan** con beneficios adicionales (streaming, cloud).
- Ofrecer **pruebas gratuitas** de servicios premium.

Impacto esperado:

- Reducir churn de Fibra en un **15%**.
- **Retener ~200 clientes/año**.

Impacto económico estimado: ~180.000 €/año.

9.4 Recomendación 4: Segmentación por valor (Prioridad MEDIA)

Hallazgo: los churners pagan más (+21%).

Acción:

- **Identificar clientes de alto valor** (MonthlyCharges > 80€).

- Ofrecer **beneficios adicionales** sin subir el precio.
- **Upselling inteligente**: por el mismo precio, añadir servicios.
- **Programa VIP** para clientes top.

Impacto esperado:

- Aumentar la retención en segmento premium en un **25%**.
- **Retener ~120 clientes/año**.

Impacto económico estimado: ~130.000 €/año.

9.5 Recomendación 5: Despliegue del modelo (Prioridad MEDIA)

Acción:

- **Integrar el modelo Random Forest** en el CRM.
- **Actualización semanal** de probabilidades de churn.
- **Alertas automáticas** cuando un cliente supere 0.70.
- **A/B testing** de las campañas de retención.

Impacto esperado:

- **ROI del modelo**: reducción del churn del 5% en el primer año.

10. Conclusiones

10.1 Conclusiones técnicas

1. **Random Forest es el mejor modelo** con AUC-ROC 0.8445 y F1 0.6350.
2. **Los modelos tradicionales superan a la red neuronal** en este dataset tabular (hallazgo habitual con pocas features).
3. **El tratamiento del desbalance** con `class_weight='balanced'` es crucial.
4. **El tipo de contrato** es el factor más determinante (importancia 41,4% en GB).

10.2 Conclusiones de negocio

1. **El 26,54% de los clientes abandonan** cada año.
2. **Los contratos mensuales y la Fibra Óptica** concentran el mayor churn.
3. **Los primeros 18 meses** son críticos para la retención.
4. **El churn es prevenible** con acciones concretas.

10.3 Impacto económico combinado

Recomendación	Clientes retenidos/año	Impacto (€)
Contratos largos	150	135.000
Retención temprana	100	90.000

Recomendación	Clientes retenidos/año	Impacto (€)
Mejora Fibra Óptica	200	180.000
Segmentación por valor	120	130.000
TOTAL	570	535.000 €/año

Inversión estimada: 80.000 € (campanías + desarrollo).

ROI estimado: 6.7x en el primer año.

11. Anexos

Anexo A: Estructura del proyecto

Reto9_BusinessAnalytics/		
├─ datos/		
└─ raw/	(dataset original)	
└─ limpios/	(X_train, X_test, y_train, y_test)	
├─ scripts/	(6 scripts Python)	
├─ notebooks/	(Colab - red neuronal)	
├─ modelos/	(4 modelos + scaler)	
├─ salidas/		
└─ figuras/	(19 PNG)	
└─ resultados/	(CSVs de métricas)	
├─ dashboard/	(Power BI .pbix)	
└─ docs/	(documentación)	

Anexo B: Tecnologías utilizadas

Herramienta	Versión	Uso
Python	3.13	Lenguaje principal
pandas	3.0.5	Manipulación de datos
scikit-learn	1.5.x	Modelos ML
TensorFlow	2.20	Red neuronal
matplotlib	3.11.2	Visualizaciones
seaborn	0.13.2	Visualizaciones estadísticas
Power BI	Desktop	Dashboard

Anexo C: Glosario

Término	Definición
Churn	Abandono de clientes
AUC-ROC	Área bajo la curva ROC
F1-score	Media armónica de Precision y Recall
Feature importance	Importancia de cada variable en el modelo
Class weight	Peso asignado a cada clase para compensar desbalance

FIN DE LA DOCUMENTACIÓN

Documento generado por Judit Giravent — 09/2026