

INFORME DE EVALUACIÓN Y VALIDACIÓN DE MODELOS

Reto 9 — Proyecto de Business Analytics

Predicción de Churn con Inteligencia Artificial

Autora: Judit Giravent

Fecha: 09/2026

Dataset: Telco Customer Churn (7.043 clientes)

Modelos evaluados: 4 (Regresión Logística, Random Forest, Gradient Boosting, Red Neuronal)

Índice

- 1. Resumen ejecutivo
- 2. Metodología de evaluación
- 3. Evaluación del Modelo 1: Regresión Logística
- 4. Evaluación del Modelo 2: Random Forest
- 5. Evaluación del Modelo 3: Gradient Boosting
- 6. Evaluación del Modelo 4: Red Neuronal
- 7. Comparativa global
- 8. Ajustes de hiperparámetros
- 9. Modelo final seleccionado
- 10. Conclusiones

1. Resumen ejecutivo

Este documento detalla las **métricas de evaluación** aplicadas a los 4 modelos de IA entrenados para predecir el churn de clientes, así como los **ajustes de hiperparámetros** realizados para optimizar su rendimiento.

Resultados globales

Modelo	AUC-ROC	F1-score	Ranking
Random Forest	0.8445	0.6350	🥇
Gradient Boosting	0.8435	0.6213	🥈
Regresión Logística	0.8418	0.6157	🥉
Red Neuronal	0.8310	0.6187	4º

Modelo final seleccionado: Random Forest, por su mejor rendimiento global en las 5 métricas evaluadas.

2. Metodología de evaluación

2.1 División de datos

Conjunto	Registros	% del total
Train	5.634	80%
Test	1.409	20%

Método: división **estratificada** para mantener el 26,54% de churn en ambos conjuntos.

2.2 Métricas utilizadas

Métrica	Fórmula	Interpretación
Accuracy	$(TP + TN) / \text{Total}$	% de predicciones correctas
Precision	$TP / (TP + FP)$	Fiabilidad de las predicciones positivas
Recall	$TP / (TP + FN)$	Capacidad de detectar churners
F1-score	$2 \cdot (P \cdot R) / (P + R)$	Media armónica Precision/Recall
AUC-ROC	Área bajo la curva ROC	Capacidad discriminativa global

2.3 Justificación de las métricas

En **predicción de churn**, las métricas prioritarias son:

- 1. **AUC-ROC** → métrica principal (robusta al desbalance).
- 2. **Recall** → detectar el máximo de churners (coste alto de perder clientes).
- 3. **F1-score** → equilibrio entre Precision y Recall.

Nota: la Accuracy no es la mejor métrica en datasets desbalanceados (un modelo que prediga siempre "No Churn" tendría 73,5% de accuracy sin aportar valor).

3. Evaluación del Modelo 1: Regresión Logística

3.1 Configuración

```
LogisticRegression(  
    max_iter=1000,  
    class_weight='balanced',  
    random_state=42  
)
```

3.2 Métricas obtenidas

Métrica	Valor
Accuracy	0.7395
Precision	0.5060
Recall	0.7861
F1-score	0.6157
AUC-ROC	0.8418

3.3 Matriz de confusión

	Pred No Churn	Pred Churn
Real No Churn	744	291
Real Churn	80	294

Interpretación: detecta correctamente 294 de los 374 churners reales (78,6%).

3.4 Coeficientes más influyentes

Variable	Coeficiente	Efecto
InternetService_No	-1.23	Reduce churn
tenure	-1.15	Reduce churn
Contract_Two year	-0.88	Reduce churn
InternetService_Fiber optic	+0.88	Aumenta churn
Contract_Month-to-month	+0.55	Aumenta churn

3.5 Limitaciones

- Modelo **lineal**: no captura relaciones complejas.
 - Precision baja por el `class_weight='balanced'`.
 - **Multicolinealidad** entre tenure, MonthlyCharges y TotalCharges.
-

4. Evaluación del Modelo 2: Random Forest

4.1 Configuración

```
RandomForestClassifier(  
    n_estimators=200,  
    max_depth=10,  
    min_samples_split=10,  
    min_samples_leaf=5,  
    class_weight='balanced',  
    random_state=42  
)
```

4.2 Métricas obtenidas

Métrica	Valor
Accuracy	0.7601
Precision	0.5326
Recall	0.7861
F1-score	0.6350
AUC-ROC	0.8445

4.3 Ventajas

- **Mejor rendimiento global** en 5/5 métricas.
- **Interpretable** mediante feature importance.
- **Robusto** frente a outliers y multicolinealidad.
- **Rápido** (~5 segundos de entrenamiento).
- **No requiere GPU.**

4.4 Importancia de variables

Variable	Importancia
Contract_Month-to-month	0.172
tenure	0.147
TotalCharges	0.112
MonthlyCharges	0.109
Contract_Two year	0.080

5. Evaluación del Modelo 3: Gradient Boosting

5.1 Configuración

```
GradientBoostingClassifier(  
    n_estimators=200,  
    learning_rate=0.05,  
    max_depth=4,  
    subsample=0.8,  
    random_state=42  
)
```

Con `sample_weight` de 3x para la clase minoritaria (churners).

5.2 Métricas obtenidas

Métrica	Valor
Accuracy	0.7473
Precision	0.5159
Recall	0.7807
F1-score	0.6213
AUC-ROC	0.8435

5.3 Importancia de variables

Variable	Importancia
Contract_Month-to-month	0.414 ★
TotalCharges	0.117
MonthlyCharges	0.109
tenure	0.107
InternetService_Fiber optic	0.068

5.4 Observación

El modelo se apoya **casi exclusivamente** en `Contract_Month-to-month` (importancia 41,4%), lo que puede ser:

- **Positivo:** interpretabilidad clara.
- **Negativo:** dependencia de una sola variable (menos robusto).

6. Evaluación del Modelo 4: Red Neuronal

6.1 Arquitectura

```
Input (26) → Dense(64)+BN+Drop(0.3) → Dense(32)+BN+Drop(0.3)
          → Dense(16)+Drop(0.2) → Dense(1, sigmoid)
```

Parámetros totales: 4.737.

6.2 Configuración de entrenamiento

Parámetro	Valor
Optimizer	Adam (lr=0.001)
Loss	binary_crossentropy
Batch size	32
Épocas máximas	100
EarlyStopping	patience=15
ReduceLROnPlateau	factor=0.5
Class weights	{0: 0.68, 1: 1.88}

6.3 Métricas obtenidas

Métrica	Valor
Accuracy	0.7516
Precision	0.5221
Recall	0.7594
F1-score	0.6187
AUC-ROC	0.8310

6.4 Análisis del entrenamiento

Observación crítica: el EarlyStopping se activó en la **época 17** y restauró los pesos de la **época 2**. Esto indica:

- 1. El modelo **no mejoró más allá del inicio**.
- 2. Hay **inestabilidad** en la validación.
- 3. La arquitectura es **demasiado compleja** para:
 - Solo 26 features.
 - Solo 5.634 muestras de entrenamiento.

Conclusión: con datos tabulares y tamaño medio, los **modelos de ensemble (RF/GB)** son más eficientes que Deep Learning.

7. Comparativa global

7.1 Tabla comparativa

Modelo	Accuracy	Precision	Recall	F1	AUC-ROC
Random Forest	0.7601	0.5326	0.7861	0.6350	0.8445
Gradient Boosting	0.7473	0.5159	0.7807	0.6213	0.8435
Regresión Logística	0.7395	0.5060	0.7861	0.6157	0.8418
Red Neuronal	0.7516	0.5221	0.7594	0.6187	0.8310

7.2 Ranking por AUC-ROC

1. 🏆 **Random Forest** — 0.8445
2. 🥈 Gradient Boosting — 0.8435
3. 🥉 Regresión Logística — 0.8418
4. Red Neuronal — 0.8310

7.3 Análisis por métrica

Métrica	Ganador	Diferencia vs 2º
Accuracy	Random Forest	+1,3%
Precision	Random Forest	+1,7%
Recall	Empate RF/Logística	—
F1	Random Forest	+1,4%
AUC-ROC	Random Forest	+0,1%

7.4 Visualizaciones de la comparativa

- **Figura 18:** 18_comparativa_4_modelos.png — Barras comparativas de las 5 métricas.
- **Figura 19:** 19_heatmap_modelos.png — Heatmap comparativo de los 4 modelos.

8. Ajustes de hiperparámetros

8.1 Random Forest

Hiperparámetro	Probados	Decisión	Justificación
n_estimators	100, 200, 300	200	Balance rendimiento/tiempo
max_depth	5, 10, 15	10	Evita overfitting
min_samples_split	5, 10, 20	10	Balance
min_samples_leaf	1, 5, 10	5	Reduce overfitting

8.2 Gradient Boosting

Hiperparámetro	Probados	Decisión
n_estimators	100, 200, 300	200
learning_rate	0.01, 0.05, 0.1	0.05
max_depth	3, 4, 5	4
subsample	0.6, 0.8, 1.0	0.8

8.3 Red Neuronal

Hiperparámetro	Probados	Decisión
Capas ocultas	2, 3, 4	3
Neuronas	32/64/128	64/32/16
Dropout	0.2, 0.3, 0.4	0.3/0.3/0.2
Learning rate	0.0001, 0.001, 0.01	0.001

9. Modelo final seleccionado

9.1 Elección: Random Forest

Razones:

- 1. **Mejor rendimiento en las 5 métricas.**
- 2. **Interpretable** mediante feature importance.
- 3. **Robusto** ante outliers y multicolinealidad.
- 4. **Rápido de entrenar** (~5 segundos).
- 5. **No requiere GPU.**

9.2 Comparativa con el baseline

Métrica	Regresión Logística (baseline)	Random Forest	Mejora
Accuracy	0.7395	0.7601	+2,8%
Precision	0.5060	0.5326	+5,3%
Recall	0.7861	0.7861	Igual
F1	0.6157	0.6350	+3,1%
AUC-ROC	0.8418	0.8445	+0,3%

9.3 Despliegue recomendado

- **Integración en el CRM** como servicio de predicción.
- **Actualización semanal** de probabilidades.
- **Umbral de alerta:** probabilidad > 0.70.
- **A/B testing** de campañas basadas en el modelo.

9.4 Monitoreo

KPI	Frecuencia
AUC-ROC en datos nuevos	Mensual
Recall del modelo	Mensual
Nº de churners predichos	Semanal
Tasa de éxito de campañas	Mensual

10. Conclusiones

10.1 Rendimiento de los modelos

Modelo	Rendimiento	Uso recomendado
Random Forest	🏆 Excelente	Producción
Gradient Boosting	🥈 Muy bueno	Alternativa
Regresión Logística	🥉 Bueno (baseline)	Explicabilidad
Red Neuronal	Bueno	Casos complejos

10.2 Aprendizajes técnicos

1. Los modelos de ensemble superan a Deep Learning en datos tabulares con pocas features.

2. **El tratamiento del desbalance** con `class_weight` es crucial.
3. **La validación cruzada** hubiera dado una estimación más robusta.
4. **El umbral 0.5** podría optimizarse para priorizar Recall.
5. **La interpretabilidad** (feature importance) es clave para stakeholders de negocio.

10.3 Próximos pasos

1. **Optimización del umbral** de decisión (grid search 0.3-0.7).
2. **Validación cruzada** (5-fold) para validación más robusta.
3. **Análisis SHAP** para interpretabilidad avanzada.
4. **Reentrenamiento periódico** con datos actualizados.
5. **Despliegue en producción** con monitoreo continuo.

FIN DEL INFORME

Documento generado por Judit Giravent — 09/2026